

Morphologie mathématique sur des graphes: Segmentation d'œdèmes dans le cerveau

de Sousa Silva, Raul Alfredo

Sorbonne Université

Février 2020

- 1 Introduction
 - Graphes
 - Morphologie mathématique
- 2 Application
 - Approche 1
 - Approche 2
 - Approche 3
 - Mesures d'évaluation
- 3 Résultats
- 4 Conclusion

- Graphe : $G = (V, E)$
- Chaque sommet, ainsi que chaque arête, peut être caractérisé par une grandeur \vec{X} .
- Applications : débruitage, la segmentation, la détection de contours, la détection de mouvement, la compression de données, ainsi que la reconnaissance d'objets et le recalage d'objets
- Types de graphes :
 - ▶ Trame discrète et graphe de pixels
 - ▶ k-plus proches voisins (k-PPV)
 - ▶ Voisins à distance d
 - ▶ Triangulation de Delaunay
 - ▶ Graphe de voisinage relatif
 - ▶ Arbre couvrant le poids minimal

Graphes

Graphcut :

- Introduit par Greig en 1989 [1].
- Solution très rapide et efficace pour un problème NP-difficile (dans le cas multi-classes).
- Applications en segmentation, calcul de profondeur dans des images, calcul des cartes de disparités et autres.
- Solution optimale dans le cas binaire et borne supérieure estimée dans le cas multi-classes.

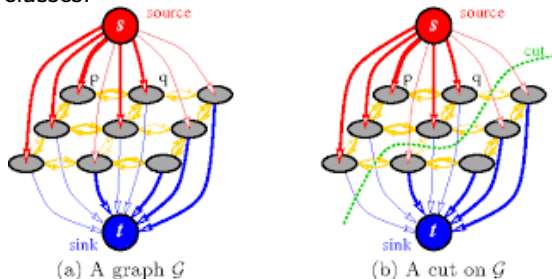


Figure – Illustration de la technique *Graphcut* Source [2]

- Développée à l'origine pour l'étude des matériaux poreux, la morphologie mathématique a été rapidement reconnue internationalement et plusieurs groupes de recherche ont été créés pour l'étudier.
- Opérateurs élémentaires : dilatation, érosion, ouverture et fermeture.
- L'extension aux images : $I : \mathbb{R}^2 \rightarrow \mathbb{R}^n$. Pourtant, l'extension au cas multispectral exige une analyse non-triviale.


Morphologie mathématique

Ligne de partage des eaux :

- Image vue comme un paysage du \mathbb{R}^2 .
- Partition de l'espace entre plusieurs minima locaux.
- Préserve les contours importants.



(a) Image Originale



(b) LPE appliquée à l'image originale

Figure – Résultat de la ligne de partage des eaux appliquée à une image

- 1 Introduction
 - Graphes
 - Morphologie mathématique


- 2 Application
 - Approche 1
 - Approche 2
 - Approche 3
 - Mesures d'évaluation

- 3 Résultats


- 4 Conclusion

Contexte

- Objectif : Segmenter les zones d'œdème/tumeur.
- Base de données : BRATS 750 sujets avec images 3D d'IRM en 4 modalités chacune : FLAIR, T1w, T1-gd, T2w.
- Segmentation de référence divisé en 4 parties : fond, œdème, tumeur non-rehaussée, tumeur rehaussée.



(a) Image FLAIR



(b) Référence

Figure – Exemple d'image de la base de données

Principe : LPE + coupure de graphes. Inspiré du travail de Stawiaski [3].

- Marquage de l'image par indication d'une boîte ;
- Ligne de partage des eaux (Low-level Watershed) ;
- Calcul des poids ;
- Construction du graphe d'adjacence de régions ;
- Coupure du graphe ;
- Reconstruction de l'image d'étiquettes ;

Construction du graphe d'adjacence de régions

Poids de liaison entre les zones donné par une longueur du contour entre deux zones :

$$w_{r_i, r_j} = |C_{(r_i, r_j)}|_R = \sum_{\substack{m \in r_i, \\ n \in r_j, \\ \text{tq } e_{m,n} \in F_{(r_i, r_j)}}} g(\max\{\|\nabla I(m)\|, \|\nabla I(n)\|\})$$

où, r_i, r_j , qui sont deux régions de l'image I ,
 $F_{(r_i, r_j)} = \{e_{m,n} \in E \mid m \in r_i, n \in r_j\}$, E est l'ensemble d'arêtes du graphe de pixels prédéfini sur l'image I , et

$$g(\|\nabla I(p)\|) = \left(\frac{1}{1 + \|\nabla I(p)\|} \right)^k$$

Approche 1

- Reproduction du travail de Stawiaski.
- Zones marquées sont forcées au label avec poids infini.
- Soit M_s l'ensemble de pixels marquées comme appartenant à l'œdème/tumeur et M_t l'ensemble de pixels appartenant au fond/cerveau sain ; les poids des zones sera donné par :

$$w_{r_i,s} = \begin{cases} \infty, & \text{si } \exists p \in r_i \mid p \in M_s \\ 0, & \text{sinon} \end{cases} \quad w_{r_i,t} = \begin{cases} \infty, & \text{si } \exists p \in r_i \mid p \in M_t \\ 0, & \text{sinon} \end{cases}$$

- Si jamais r_i a des pixels appartenant à M_s et M_t il sera préférentiellement mis en M_t (fond).

- Inclusion d'un terme d'attache aux données, plutôt qu'un marquage.

$$w_{r_i, \{s, t\}} = \frac{(\bar{l}_{r_i} - \mu_{x_{\{s, t\}}})^2}{\sigma^2}$$

- Le poids entre les régions est maintenu.
- Moyenne et variance calculées à partir du marquage.
- Une seule variance : la plus petite entre les variances des deux zones.
Mais il faut qu'elles soient suffisamment similaires (la plus grande doit être $< 2 \times$ la variance plus petite).

Approche 3

- Fusion des approches 1 e 2.
- Poids infini dans des zones marquées et terme d'attache aux données ailleurs.
- Mais maintenant au lieu de diviser par la variance, nous allons diviser pour un terme fixe pour toutes les images.
- L'objectif c'est que ces poids de liaison aux classes soient au même ordre de grandeur des poids de liaison des régions.
- Avec ce terme nous pouvons passer de l'approche 1 au 2 ou faire un hybride.

$$w_{r_i,s} = \begin{cases} \infty, & \text{si } \exists p \in r_i \mid p \in M_s \\ 0, & \text{si } \exists p \in r_i \mid p \in M_t \\ \frac{(\bar{I}_{r_i} - \mu_{x_s})^2}{\beta}, & \text{sinon} \end{cases} \quad w_{r_i,t} = \begin{cases} \infty, & \text{si } \exists p \in r_i \mid p \in M_t \\ 0, & \text{si } \exists p \in r_i \mid p \in M_s \\ \frac{(\bar{I}_{r_i} - \mu_{x_t})^2}{\beta}, & \text{sinon} \end{cases}$$

- ① Critère de Dice (*DICE*) :

$$DICE = \frac{2|V_{seg} \cap V_{ref}|}{|V_{seg}| + |V_{ref}|}$$

- ② Distance de surface absolue symétrique moyenne

$$SD_{abs} = \frac{1}{|C_{seg}|} \sum_{s \in C_{seg}} |d(s, C_{ref})| + \frac{1}{|C_{ref}|} \sum_{r \in C_{ref}} |d(r, C_{seg})|$$

- ③ Différence de volume absolu relatif

$$VD = 100 * \left| 1 - \frac{V_{seg}}{V_{ref}} \right|$$


- 1 Introduction
 - Graphes
 - Morphologie mathématique

- 2 Application
 - Approche 1
 - Approche 2
 - Approche 3
 - Mesures d'évaluation

- 3 Résultats

- 4 Conclusion


Premier approche



(a) Dice : 0.781 SD_{abs} : 2.022mm Voldif : 32.9% (b) Dice : 0.223 SD_{abs} : 17.56mm Voldif : 78.6% (c) Dice : 0.593 SD_{abs} : 4.346mm Voldif : 51.4%

Figure – Images FLAIR avec contour de la segmentation de référence en vert et celle trouvé par l'algorithme en rouge


Deuxième approche



(a) Dice : 0.016 SD_{abs} : 17.935mm Voldif : 98.1% (b) Dice : 0.4 SD_{abs} : 5.262mm Voldif : 69.5% (c) Dice : 0.557 SD_{abs} : 14.124mm Voldif : 50.7%

Figure – Images FLAIR avec contour de la segmentation de référence en vert et celle trouvée par l'algorithme en rouge

Troisième approche



(a) Dice : 0.587 SD_{abs} : 4.255mm Voldif : 56.9% (b) Dice : 0.209 SD_{abs} : 18.415mm Voldif : 87.4% (c) Dice : 0.782 SD_{abs} : 2.714mm Voldif : 30.5%

Figure – Images FLAIR avec contour de la segmentation de référence en vert et celle trouvée par l'algorithme en rouge

Approche	Dice	VD [%]	SD _{abs} [mm]
1 ^{er} approche	0.453	59.45	10.65
2 ^{eme} approche	0.304	66.96	15.68
3 ^{eme} approche	0.44	60.43	9.53
Isensee[4]	0.677	-	-
Perslev[5]	0.60	-	-
Yuan[6]	0.815	-	2.53

Table – Valeurs moyennes des mesures évaluées sur 50 images de la base de données comparé à des résultats d'autres articles.

Si on supprime les résultats $\text{Dice} < 0.25$ pour la première approche les mesures s'améliorent : Dice : 0.692, SD_{abs} : 2.25 mm, VD : 34.7 %.

- 1 Introduction
 - Graphes
 - Morphologie mathématique
- 2 Application
 - Approche 1
 - Approche 2
 - Approche 3
 - Mesures d'évaluation
- 3 Résultats
- 4 Conclusion

Avantages/Inconvénients

Avantages

- C'est une méthode avec un bon potentiel ;
- Ne dépend pas d'apprentissage ;
- Pas de paramètres à régler ;

Inconvénients

- C'est lent (environ 40 min/image) ;
- Dépend d'un bon marquage ;
- Instable par rapport à la détection ;

Améliorations possibles

- Marquage en plus d'une coupe ;
- Parallélisation de la construction du graphe ;
- Choisir $\max_{Vol}(\text{Approche 1} ; \text{Approche 2} ; \text{Approche 3})$;
- Pré/Post-traitement (qui a été négligé dans ce travail) ;
- Approche par PCA ;



Dorothy M Greig, Bruce T Porteous, and Allan H Seheult.

Exact maximum a posteriori estimation for binary images.

Journal of the Royal Statistical Society : Series B (Methodological),
51 :271–279, 1989.



Yuri Boykov and Olga Veksler.

Graph cuts in vision and graphics : Theories and applications.

In *Handbook of mathematical models in computer vision*, pages 79–96.
Springer, 2006.



Jean Stawiaski.

Mathematical morphology and graphs : Application to interactive medical image segmentation.

PhD thesis, Ecole Nationale Supérieure des Mines de Paris, 2008.



Fabian Isensee, Jens Petersen, Andre Klein, David Zimmerer, Paul F Jaeger, Simon Kohl, Jakob Wasserthal, Gregor Koehler, Tobias Norajitra, Sebastian Wirkert, et al.

nnu-net : Self-adapting framework for u-net-based medical image segmentation.

arXiv preprint arXiv :1809.10486, 2018.



Mathias Perslev, Erik Bjørnager Dam, Akshay Pai, and Christian Igel. One network to segment them all : A general, lightweight system for accurate 3d medical image segmentation.

In International Conference on Medical Image Computing and Computer-Assisted Intervention, pages 30–38. Springer, 2019.



Wenguang Yuan, Jia Wei, Jiabing Wang, Qianli Ma, and Tolga Tasdizen.

Unified attentional generative adversarial network for brain tumor segmentation from multimodal unpaired images.

In International Conference on Medical Image Computing and Computer-Assisted Intervention, pages 229–237. Springer, 2019.

Approche par PCA

- *Rappel* : Base de données : BRATS 750 sujets avec images 3D d'IRM en 4 modalités chacune : **FLAIR**, **T1w**, **T1-gd**, **T2w**.
- Pourquoi ne pas chercher l'information importante dans chaque image ?
- Appliquer PCA ferait ressortir l'information la plus importante.
- Approche :
 - 1 Normaliser images (moyenne 0 et écart-type 1) ;
 - 2 Appliquer PCA aux 4 images ;
 - 3 Reconstituer l'image à partir du premier vecteur propre ;
 - 4 Seuiller l'image ;
- Incroyablement il semble avoir un seuil qui marche dans n'importe quelle image !
- De plus les autres vecteurs propres peuvent aussi être utiles pour retrouver les autres classes.

Résultats

Dice = 0.609 $SD_{abs} = 12.539\text{mm}$ VD = 36.9% (Valeurs référents à la classe œdème/tumeur)

